

Contrastive Learning — Report Esperimento Paper-Faithful

Data: 24 Febbraio 2026

1. Obiettivo

Implementazione **completamente fedele** al paper:

Thor & Nettelblad (2025) — "Dimensionality Reduction of Genetic Data using Contrastive Learning"

L'obiettivo è apprendere una rappresentazione compressa del genoma caprina su una **sfera unitaria 3D** tramite contrastive learning, mantenendo alta la discriminabilità tra razze. A differenza di un VAE, questo approccio non ricostruisce il genotipo ma impara direttamente uno spazio metrico dove campioni della stessa razza sono vicini e campioni di razze diverse sono lontani.

2. Architettura del Modello

Encoder (GeneticEncoder)

L'encoder mappa il genotipo SNP su una sfera unitaria tridimensionale:

```
Input (B, M) → One-Hot (B, M, 4) → Conv1D(4→5, k=3) → SiLU
→ Conv1D(5→5, k=3) → SiLU → Flatten → Dense(256) → BN → SiLU
→ Dense(256) → BN → SiLU → Dense(256) → BN → SiLU
→ Dense(3) → L2-normalize → Sfera 3D
```

- **Parametri totali:** 59.7M (trainable)
- **Output:** Vettore 3D normalizzato L2 (sulla sfera unitaria)
- **Attivazione:** SiLU/Swish ($x \cdot \sigma(x)$)

Augmentation (GeneticAugmentation)

Data augmentation specifica per dati genetici, applicata ad ogni epoch:

1. **Flip allelico:** Con probabilità $p_{\text{flip}} \sim U(0.01, 0.99)$ per campione, gli alleli vengono "flippati" ($0 \leftrightarrow 1 \leftrightarrow 2$)
2. **Masking:** Con probabilità $p_{\text{mask}} \sim U(0.01, 0.99)$, gli SNP vengono mascherati (impostati a -1 = "sconosciuto")
3. **One-Hot Encoding:** $0 \rightarrow [1, 0, 0, 0] \mid 1 \rightarrow [0, 1, 0, 0] \mid 2 \rightarrow [0, 0, 1, 0] \mid -1 \rightarrow [0, 0, 0, 1]$

Loss Function — Centroid N-Pair Loss (Eq. 6 del paper)

$$L_{\text{centroid}}(\mathcal{Z}) = \log \left(1 + \sum_{i=1}^{N-1} \left[\frac{\exp(\tilde{z}_i^{\top} \tilde{z}_i^{-})}{\exp(\tilde{z}_i^{\top} \tilde{z}_i^{+})} - e^{-2} \right] \right) !$$

La somma sui negativi è **dentro il logaritmo** — differenza cruciale rispetto all'implementazione naïve.

Passi del calcolo: 1. **Centroide:** $C_i = (z + 2z^{-} + z^{+}) / 4$ 2. **Centratura:** $z_{-c} = z - C$, $z^{+}_{-c} = z^{+} - C$, $z^{-}_{-c} = z^{-} - C$ 3.

Scaling: $\mu_i = \max(\|z_{-c}\|^2, \|z^{+}_{-c}\|^2, \|z^{-}_{-c}\|^2)$, poi $\tilde{z} = z_{-c} / \sqrt{\mu}$ 4. **Loss:** Somma delle differenze di similarità (positiva vs negativa), dentro un singolo logaritmo

3. Configurazione Sperimentale

Dataset

Parametro	Valore
Dataset	ADAPTmap (capre)
Campioni totale (raw)	4,653
Razze totali (raw)	144
Soglia minima per razza	30 campioni
Razze incluse	34
Downsampling	30 campioni/razza
Campioni usati	1,020
SNP dopo QC + LD Pruning	46,565

QC Pipeline

1. **Missingness:** SNP con >10% dati mancanti rimossi → 51,255 SNP
2. **Imputazione:** Media per SNP mancanti
3. **MAF filter:** SNP con MAF < 0.01 rimossi → 51,244 SNP
4. **LD Pruning:** Window=50, $r^2 > 0.2$ → rimossi 4,679 SNP → **46,565 SNP finali**

Iperparametri (Paper-Faithful)

Parametro	Valore
Embedding dim	3 (sfera 3D)
Batch size	Full-batch (680 campioni = N_train)
Negativi per anchor	679 (N_train – 1)
Optimizer	Adam ($\beta_1=0.9$, $\beta_2=0.999$)
Learning rate	0.001
LR decay	$\times 0.99$ ogni 10 epoche (StepLR)
Max epochs	5,000
Early stopping patience	200 epoche
Augmentation flip/mask	$p \sim U(0.01, 0.99)$
K-Fold CV	3 fold
GPU	NVIDIA GeForce RTX 5070 Ti

Differenze chiave rispetto all'implementazione naïve

Componente	Versione naïve	Versione paper-faithful
Loss	<code>log(1+clamp(term))</code> per-pair	<code>log(1 + Σ term)</code> — somma dentro il log
Batch size	128 (mini-batch)	Full-batch (N_train)
Negativi	127 per anchor	N_train – 1 per anchor
Optimizer	AdamW	Adam (nessun weight decay)
LR decay	ExponentialLR ogni epoch	StepLR $\gamma=0.99$ ogni 10 epoche
Augmentation	flip=mask=0.90	flip=mask=0.99, U(0.01, 0.99)
Epochs	100	5,000

4. Risultati

Metriche

Metrica	Descrizione	Obiettivo
KNN Accuracy @3	Accuratezza di un classificatore KNN (k=3) sugli embedding 3D. Misura quanto bene lo spazio appreso separa le razze.	↑ Alto
KNN F1-Score @3	F1-score macro del classificatore KNN. Tiene conto del bilanciamento tra precision e recall per tutte le classi.	↑ Alto
KNN Recall @3	Recall macro del classificatore KNN. Misura la capacità del modello di identificare correttamente tutti i campioni di ogni razza (sensibilità media tra le classi).	↑ Alto
Silhouette Score	Coesione intra-cluster e separazione inter-cluster nello spazio 3D. Range: [-1, 1].	↑ Alto
Davies-Bouldin Index	Rapporto tra dispersione intra-cluster e distanza inter-cluster.	↓ Basso

Risultati per Fold

Fold	KNN Accuracy @3	Silhouette	Epoche (best ckpt)	Val Loss
1	0.9382	0.5249	1,078	2.1516
2	0.9706	0.5261	1,734	2.0142
3	0.9529	0.5768	1,027	2.1644

Risultati Medi (3-Fold CV)

Metrica	Valore
KNN Accuracy @3	0.9539 (95.39%)
KNN F1-Score @3	0.9519 (95.19%)
Silhouette Score	0.5426
Davies-Bouldin Index	0.9442

Analisi per Razza (dal best fold — Fold 2)

Dalla confusion matrix del best fold (KNN @3):

Razze con 100% di recall (classificazione perfetta): ABR, ALP, ANG, BOE, BRI, BUR, BUT, CAM, CAN, CAS, CRE, CRS, GGT, GUM, KEF, KLS, LND, LNR, MLG, MOX, NBN, RME, SAR, SID, WAD, WYG (26/34 razze)

Razze con errori di classificazione:



Razza	Recall	Confusa con
BRK	90%	NBN (10%)
KAM	90%	SAA (10%)
OSS	90%	SID (10%)
PAT	90%	OSS (10%) — confonde anche con CAS
RAN	90%	ALP (10%)
SAA	90%	CRS (10%)
SEA	70%	WYG (30%)
TED	90%	CRS (10%)

SEA (Shell East African) è la razza più problematica: il 30% viene confuso con WYG (West African Goat), probabilmente per vicinanza genetica geografica (Africa).

5. Visualizzazioni

A. Distribuzione Dataset



Dataset perfettamente bilanciato: 30 campioni per ognuna delle 34 razze (1,020 totale).



B. Embedding — Proiezione Equal Earth e Sfera 3D


Gli embedding 3D vengono proiettati sia su piano 2D tramite Equal Earth projection (Šavrič et al. 2019) sia visualizzati sulla sfera unitaria.

- **Equal Earth (sinistra):** I cluster sono ben separati, con poche sovrapposizioni
- **Sfera 3D (destra):** Le razze occupano regioni distinte sulla sfera



C. Confusion Matrix KNN @3

Matrice normalizzata per riga (recall per classe). La diagonale scura indica alta precisione.



7. Conclusioni

Punti di forza:

1. **Compressione estrema:** 46,565 SNP → 3 dimensioni con 95.4% di accuracy — ogni razza occupa una regione distinta sulla sfera 3D
2. **26 razze su 34 classificate perfettamente** (100% recall)
3. **Interpretabilità:** La sfera 3D è direttamente visualizzabile e interpretabile (proiezione Equal Earth)
4. **Fedeltà al paper:** L'implementazione riproduce fedelmente il metodo originale (fix critico della loss function)

Limitazioni:

1. **Silhouette moderato (0.54):** I cluster sono meno compatti rispetto al VAE (0.72) — probabile limite della compressione a sole 3 dimensioni
2. **SEA confusa con WYG (30%):** Alcune razze dell'Africa hanno embedding sovrapposti — possibile vicinanza genetica reale
3. **Training costoso:** 5,000 epoche full-batch con 59.7M parametri
4. **Nessuna capacità generativa:** A differenza del VAE, non può ricostruire il genotipo né generare nuovi campioni