

VMGP Grid Search - Report Esperimenti

Data: 23 Febbraio 2026

1. Obiettivo

Esplorazione sistematica dello spazio degli iperparametri del modello VMGP (Variational Auto-Encoder Multi-task Genomic Prediction) tramite una griglia completa di **20 combinazioni**: - **Min Samples per Razza**: 30, 40, 50, 60, 70 (solo campioni reali, NO SMOTE) - **Dimensione Latent Space**: 32, 64, 96, 128 - **Task**: Solo classificazione breed - **Validazione**: 3-Fold Cross Validation per ogni esperimento

Differenze rispetto agli esperimenti precedenti

Aspetto	Esperimenti Precedenti (Feb 5)	Griglia Attuale (Feb 23)
Combinazioni	~10 esperimenti mirati	20 combinazioni (griglia completa)
Latent Dims	32, 64, 96	32, 64, 96, 128
Min Samples	20, 30, 40, 50	30, 40, 50, 60, 70
SMOTE	Testato Sì/NO	Solo dati reali (NO SMOTE)
Multi-task	Breed + Continente	Solo Breed
Metrica chiave	Accuracy + Silhouette	Cohen's Kappa (chance-adjusted)
K-Fold CV	3-Fold	3-Fold

Glossario metriche

Metrica	Descrizione	Obiettivo
Breed Accuracy	Accuratezza raw del classificatore KNN sui dati compressi. Non direttamente comparabile tra soglie diverse (classificare 10 razze è più facile che classificarne 34).	 Alto
Cohen's Kappa	Accuratezza chance-adjusted : tiene conto del numero di classi e del bilanciamento. Metrica preferita per confronti equi tra soglie diverse.	 Alto
Generalization (GE)	Accuratezza su animali mai visti (Validation Set). Misura la capacità di generalizzazione.	 Alto
Silhouette Score	Quanto sono ben separati i cluster (razze) nello spazio latente. >0.7: Ottimo. <0.5: Scarso.	 Alto
Davies-Bouldin	Rapporto tra dispersione intra-cluster e distanza inter-cluster. Più basso = cluster più compatti e separati.	 Basso
Reconstruction MSE	Errore medio di ricostruzione del genotipo dopo compressione.	 Basso

2. Miglior Modello

Samples_30_LatDim_96 (per Cohen's Kappa — confronto equo)

Performance (media ± std su 3 fold): - **Cohen's Kappa:** 0.9714 — Il più alto di tutta la griglia - **Breed Accuracy:** 0.9731 (97.31%) - **Generalization (GE):** 0.9724 (97.24%) - **Silhouette Score:** 0.7210 - **Davies-Bouldin:** 0.5737 - **Reconstruction MSE:** 0.4018

Configurazione: - **Latent Dimension:** 96 - **Min Samples per Class:** 30 - **Numero Razze:** 34 (il massimo testato) - **Numero SNPs:** 49,586 - **Balancing:** Solo downsampling (cap a 30), NO SMOTE - **Task:** Solo classificazione breed - **K-Fold CV:** 3 fold

Perché questo modello? Pur non avendo l'Accuracy raw più alta (che spetta a soglie con meno razze, quindi task più facili), ha il **Kappa più alto**, dimostrando che riesce a distinguere **34 razze** con precisione superiore rispetto a modelli con meno classi — una volta corretta per il caso.

3. Classifica Top 5 Modelli (per Cohen's Kappa)

Rank	Experiment	Razze	Kappa	Accuracy	GE	Silhouette
1	Samples_30_LatDim_96	34	0.9714	0.9731	0.9724	0.7210
2	Samples_40_LatDim_128	26	0.9710	0.9731	0.9742	0.7053
3	Samples_40_LatDim_96	26	0.9710	0.9731	0.9742	0.7083
4	Samples_40_LatDim_32	26	0.9710	0.9731	0.9742	0.7388
5	Samples_50_LatDim_128	16	0.9708	0.9737	0.9741	0.6990

Nota: La soglia **min_samples=40** domina le posizioni 2-4 con tre diverse dimensioni latenti che raggiungono tutte Kappa=0.9710. Questo suggerisce che a 40 campioni il modello è **robusto rispetto alla dimensione latente**.

4. Tabella Completa: Tutti i 20 Esperimenti

Min Samples = 30 (34 razze, 49,586 SNPs)

Latent Dim	Accuracy	Kappa	GE	Silhouette	Davies-Bouldin	MSE
96	0.9731	0.9714	0.9724	0.7210	0.5737	0.4018
32	0.9711	0.9692	0.9711	0.7357	0.5625	0.4029
64	0.9708	0.9689	0.9721	0.7225	0.5853	0.4019
128	0.9688	0.9667	0.9681	0.7157	0.6099	0.4025

Min Samples = 40 (26 razze, 49,640 SNPs)

Latent Dim	Accuracy	Kappa	GE	Silhouette	Davies-Bouldin	MSE
32	0.9731	0.9710	0.9742	0.7388	0.5004	0.4012
96	0.9731	0.9710	0.9742	0.7083	0.5397	0.3992
128	0.9731	0.9710	0.9742	0.7053	0.5380	0.3991
64	0.9716	0.9694	0.9734	0.7199	0.5345	0.3994

Min Samples = 50 (16 razze, 49,359 SNPs)

Latent Dim	Accuracy	Kappa	GE	Silhouette	Davies-Bouldin	MSE
128	0.9737	0.9708	0.9741	0.6990	0.5192	0.4013
32	0.9732	0.9703	0.9728	0.7405	0.4569	0.4019
96	0.9715	0.9684	0.9723	0.7055	0.5087	0.4009
64	0.9706	0.9674	0.9706	0.7131	0.5053	0.4010

Min Samples = 60 (12 razze, 49,250 SNPs)

Latent Dim	Accuracy	Kappa	GE	Silhouette	Davies-Bouldin	MSE
64	0.9738	0.9704	0.9743	0.7062	0.5221	0.4006
96	0.9734	0.9698	0.9738	0.6939	0.5436	0.3996
128	0.9729	0.9693	0.9738	0.6843	0.5433	0.4003
32	0.9714	0.9676	0.9743	0.7309	0.4857	0.3999

Min Samples = 70 (10 razze, 49,023 SNPs)

Latent Dim	Accuracy	Kappa	GE	Silhouette	Davies-Bouldin	MSE
32	0.9742	0.9703	0.9737	0.7398	0.4807	0.3939
128	0.9742	0.9703	0.9737	0.6846	0.5691	0.3942
64	0.9721	0.9679	0.9721	0.7055	0.5316	0.3936
96	0.9711	0.9668	0.9711	0.6974	0.5574	0.3945

5. Analisi: Effetto del Numero Minimo di Sample

Statistiche medie su tutte e 4 le dimensioni latenti per ogni soglia:

Min Samples	Razze	SNPs	Kappa (media)	Accuracy (media)	GE (media)	Silhouette (media)
30	34	49,586	0.9691	0.9709	0.9709	0.7237
40	26	49,640	0.9706	0.9727	0.9740	0.7181
50	16	49,359	0.9692	0.9722	0.9725	0.7145
60	12	49,250	0.9693	0.9729	0.9741	0.7038
70	10	49,023	0.9688	0.9729	0.9727	0.7068

Osservazioni: 1. Il **Kappa** è **straordinariamente stabile** lungo tutte le soglie (range: 0.9688–0.9706). Questo significa che il modello VMGP mantiene una performance *chance-adjusted* quasi identica indipendentemente dal numero di razze incluse. 2. **L'Accuracy raw cresce con meno razze** (0.9709 → 0.9729 da 30 a 70 campioni), ma questo è un artefatto: classificare 10 classi è intrinsecamente più facile che classificarne 34. Il Kappa corregge per questo. 3. **La soglia 40 ha il miglior Kappa medio** (0.9706), ma la differenza con 30 (0.9691) è minima. 4. Il **Silhouette decresce** al crescere dei campioni: con 30 campioni le "isole" sono più nette (0.7237), con 70 si sovrappongono leggermente di più (0.7068). Probabile effetto del ridotto numero di razze su come i cluster occupano lo spazio.

Conclusione: La soglia **min_samples=30** offre il miglior trade-off: include il **massimo numero di razze (34)** con **Kappa competitivo** e il **miglior clustering (Silhouette)**. Se si preferisce massimizzare GE e stabilità, **min_samples=40** è l'alternativa.

6. Analisi: Effetto della Dimensione Latente

Statistiche medie su tutte e 5 le soglie per ogni dimensione latente:

Latent Dim	Kappa (media)	Accuracy (media)	GE (media)	Silhouette (media)
32	0.9697	0.9726	0.9732	0.7371
64	0.9688	0.9718	0.9725	0.7134
96	0.9695	0.9724	0.9728	0.7052
128	0.9696	0.9725	0.9728	0.6978

Osservazioni: 1. **Le dimensioni latenti hanno un effetto trascurabile** sul Kappa (range: 0.9688–0.9697). Il modello performa quasi identicamente con 32 o 128 dimensioni. 2. **Silhouette favorisce dimensioni basse** (32: 0.7371 vs 128: 0.6978). Con meno dimensioni, i cluster sono geometricamente più compatti. 3. **La dimensione 32 è leggermente migliore su tutte le metriche** in media, suggerendo che il segnale genomico utile per la classificazione breed è comprimibile in uno spazio molto ridotto. 4. **La dimensione 64 è la peggiore** in media per Kappa (0.9688), forse in una zona intermedia non ottimale.

Conclusione: **Latent Dim = 32** è sufficiente e persino preferibile. Dimensioni maggiori non aggiungono informazione utile e peggiorano leggermente il clustering. Questo è un risultato importante per la riduzione dimensionale: il genoma discriminante per le razze caprine si comprime efficacemente in **32 dimensioni** (da ~49,500 SNPs — compressione ~1,550×).

7. Miglior Configurazione per Soglia (Best Latent Dim per ogni Min Samples)

Min Samples	Razze	Best Latent Dim	Kappa	Accuracy	GE	Silhouette	MSE
30	34	96	0.9714	0.9731	0.9724	0.7210	0.4018
40	26	128*	0.9710	0.9731	0.9742	0.7053	0.3991
50	16	128	0.9708	0.9737	0.9741	0.6990	0.4013
60	12	64	0.9704	0.9738	0.9743	0.7062	0.4006
70	10	32	0.9703	0.9742	0.9737	0.7398	0.3939

* Per min_samples=40, le dimensioni 32, 96 e 128 hanno lo stesso Kappa (0.9710). La 32 ha il miglior Silhouette (0.7388).

Pattern emergente: Con più razze (30-50), dimensioni latenti più alte (96-128) sono leggermente favorite. Con poche razze (60-70), dimensioni basse (32-64) bastano. Questo è coerente: più classi richiedono più "spazio" per essere rappresentate.

8. Confronto con Esperimenti Precedenti (5 Febbraio)

Aspetto	Miglior modello (5 Feb)	Miglior modello (23 Feb)
Esperimento	MinSamples_40_NoSMOTE_BreedOnly	Samples_30_LatDim_96
Accuracy	0.9902	0.9731
GE	0.9877	0.9724
Silhouette	0.8262	0.7210
Latent Dim	96	96
Razze	26	34
Validazione	3-Fold CV	3-Fold CV


Nota importante: Le performance raw appaiono inferiori, ma il confronto diretto non è appropriato perché: 1. La griglia attuale include **34 razze** (vs 26) per la soglia 30, un task significativamente più difficile 2. Il capping dei campioni a **min_samples** (e non a un fisso) cambia la composizione del training set 3. La metrica chiave ora è Cohen's Kappa, che fornisce un confronto più equo

9. Grafici

A. Heatmap Griglia Esperimenti

- **Righe:** Min Samples per Breed (30→70)
- **Colonne:** Latent Dimension (32→128)
- **Colore:** Verde = buono, Rosso = scarso
- **Interpretazione:** 4 heatmap separate per Accuracy, Kappa, Silhouette e GE. Cercare le celle più verdi per la configurazione ottimale.


□ Griglia Esperimenti: Min Samples × Latent Dim
(Solo dati reali, solo breed classification)



B. Andamento Metriche in 3D

- **Asse X:** Dimensione Latente (32, 64, 96, 128)
- **Asse Y:** Min Samples per Breed (30, 40, 50, 60, 70)
- **Asse Z (altezza + colore):** Valore della metrica
- **Superficie:** Interpolazione tra i 20 punti della griglia (punti rossi)
- **Interpretazione:** Superfici piatte indicano robustezza agli iperparametri; pendenze indicano sensibilità.


Andamento delle Metriche in 3D Latent Dim × Min Samples → Metrica




C. Confusion Matrix

- **1 figura per ogni soglia min_samples**, con 4 subplot (1 per latent_dim)
- **Normalizzate per riga:** ogni cella mostra la recall per classe
- **Diagonale scura:** alta recall (classificazione corretta)


Min Samples = 30 (34 razze)




Min Samples = 40 (26 razze)




Min Samples = 50 (16 razze)



Min Samples = 60 (12 razze)



Min Samples = 70 (10 razze)



10. Analisi della Confusione tra Razze

Aggregando le 20 matrici di confusione (5 soglie min_samples x 4 dimensioni latenti), è possibile identificare le razze più problematiche e le coppie che il modello confonde sistematicamente.

10.1 Razze più problematiche

Razza	#Esperimenti con errori	Recall medio	Confusa più spesso con
SEA	12/12	75.2%	BUR (42), WYG (13)
NBN	20/20	85.3%	CRE (59), SAA (38), ALP (4)
SAA	20/20	88.9%	CRE (60), SEA (20), ALP (16)
CRE	20/20	94.1%	SAA (39), NBN (23), ANG (6)
BUR	20/20	95.8%	BOE (20)
OSS	12/20	95.1%	SID (14)
ABR	8/12	94.1%	GUM (8)
BRK	18/20	96.1%	NBN (21), SID (12), CRE (2)
ANG	17/20	98.7%	CRE (10), NBN (7), LND (4)
BOE	8/20	99.1%	BUR (8)

Osservazioni: Le razze SEA (South East Anatolian), NBN (Nubian) e SAA (Saanen) sono le più critiche, con recall medio rispettivamente del 75.2%, 85.3% e 88.9%. In particolare, il cluster CRE-SAA-NBN mostra forte confusione reciproca: queste tre razze concentrano **200 errori** complessivi tra loro (CRE↔SAA: 99, CRE↔NBN: 82, NBN↔SAA: 50 errori su 20 esperimenti).

10.2 Coppie di razze più confuse


Razza A	Razza B	Errori totali
CRE	SAA	99
CRE	NBN	82
NBN	SAA	50
BUR	SEA	42
BOE	BUR	28
BRK	NBN	21
SAA	SEA	20
OSS	SID	18
ANG	CRE	16
ALP	SAA	16
BUR	SAA	16
SEA	WYG	13
BRK	SID	12
ABR	GUM	8
ANG	NBN	7

10.3 Modello migliore: Samples_30_LatDim_96


Nel modello migliore per Kappa (0.9714, 34 razze), 25 razze su 34 raggiungono recall del 100%. Le 9 razze con errori:

Razza	Recall	Campioni	Confusa con
SEA	61.1%	18	BUR (4), WYG (3)
SAA	86.0%	57	CRE (6), SEA (1), ALP (1)
NBN	88.2%	34	CRE (3), ALP (1)
CRE	91.9%	62	SAA (4), NBN (1)
BRK	92.2%	51	SID (3), CRE (1)
ABR	94.1%	17	GUM (1)
TED	94.1%	17	CRE (1)
BUR	95.8%	24	BOE (1)
OSS	95.8%	24	SID (1)

10.4 Visualizzazioni



A sinistra, il grafico a barre mostra gli errori totali per razza (colore = recall medio: verde = alto, rosso = basso). A destra, la heatmap mostra la matrice di confusione bidirezionale aggregata su tutti i 20 esperimenti.



L'andamento delle principali coppie di confusione al variare della soglia min_samples. Le coppie CRE↔SAA e CRE↔NBN dominano costantemente, ma non si riducono con l'aumento della soglia (poiché queste razze restano sempre nel dataset).

10.5 Interpretazione

1. **Cluster CRE-SAA-NBN:** Creole, Saanen e Nubian formano un triangolo di confusione reciproca con 231 errori combinati. Questo suggerisce somiglianza genetica o sovrapposizione fenotipica tra queste razze.
2. **BUR↔SEA:** Burma e South East Anatolian (42 errori) sono il secondo fatto critico; SEA ha il recall più basso in assoluto (75.2%).
3. **Confusione non simmetrica:** CRE→SAA (39 errori) è più frequente di SAA→CRE (60 errori), indicando che SAA viene confusa con CRE più spesso del viceversa.
4. **Razze con pochi campioni:** SEA (18 campioni), ABR (17), TED (17) sono le razze con meno campioni e mostrano errori — ma NBN (34 campioni) e SAA (57 campioni) hanno errori significativi anche con campioni sufficienti, indicando vera similarità genomica.